利用PySpark 打造推薦系統

David Chiu
2018/04/25

推薦問題

推薦系統適用於

- 使用者需在眾多的商品選項做取捨:
  - 使用者難以從眾多選項中找他們所想要的，雖然商品搜尋可能可以滿足需求，但如何提供使用者未知卻需要的商品？
- 依個人行為與品味做推薦
  - 如果可以找到偏好相似的使用者，便可透過偏好的相似性進行商品推薦

推薦模型

- 基於相似內容過濾
  - 基於商品內容的推薦 (文章標題、文章內容、影片特徵)
  - 可以針對使用者檔案所列的喜好做推薦
- 協同過濾法
  - 使用”群眾智慧”找出使用者偏好
  - 基於使用者的協同過濾：使用者對類似商品的偏好可推得他們有相同偏好
  - 基於商品的協同過濾：商品被類似使用者推薦時，代表性質類似
  - 類似最近鄰居法(Nearest Neighbor)

矩陣分解 (Matrix Factorization)

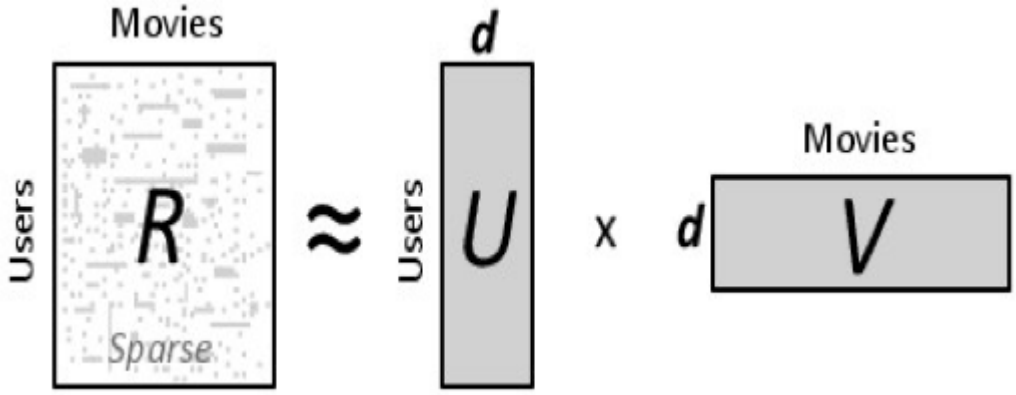

- 假設每位使用者和每樣物品都有自己的特性
- 隱性矩陣分解與顯性矩陣分解

顯性矩陣分解

- 使用者有對商品表示喜好的評價

Tom, Star Wars, 5
Jane, Titanic, 4
Bill, Batman, 3
Jane, Star Wars, 2
Bill, Titanic, 3

User / Item	Batman	Star Wars	Titanic
Bill	3	3	
Jane		2	4
Tom		5	

低秩矩陣逼近 (Low-rank approximation)

- 使用者對商品評價的稀疏矩陣可分解為使用者對潛在因子(風格、種類)的喜好程度向量與每個商品潛在因子含量(風格、種類)的向量

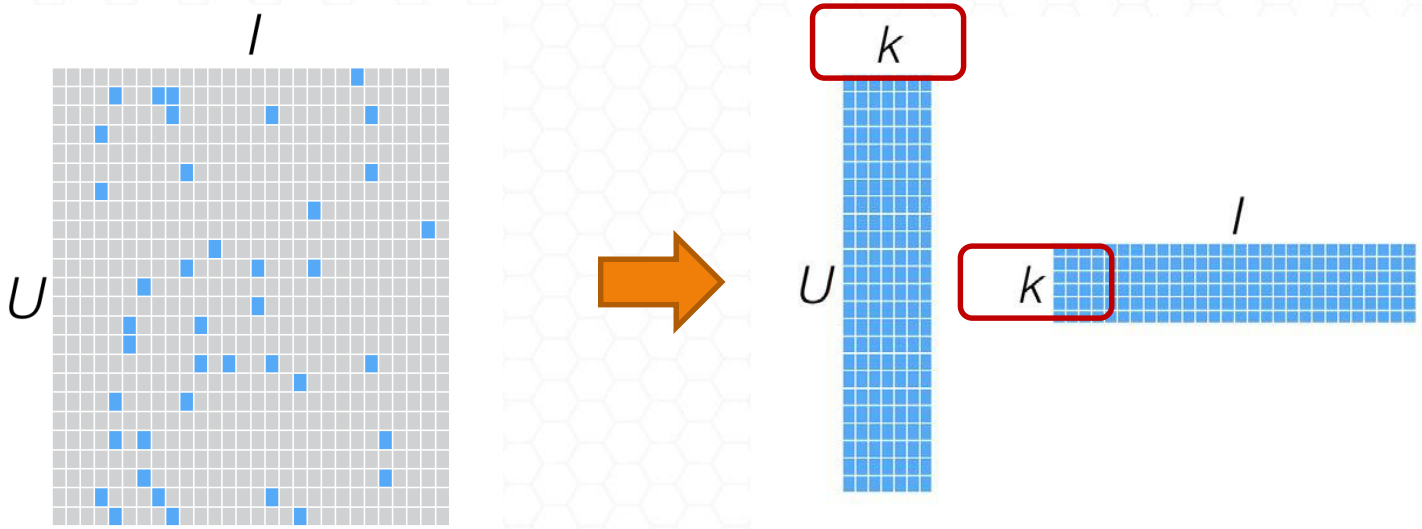

稀疏矩陣 (低秩矩陣)

分解矩陣應用

- 利用使用者與商品向量的乘積計算使用者評分

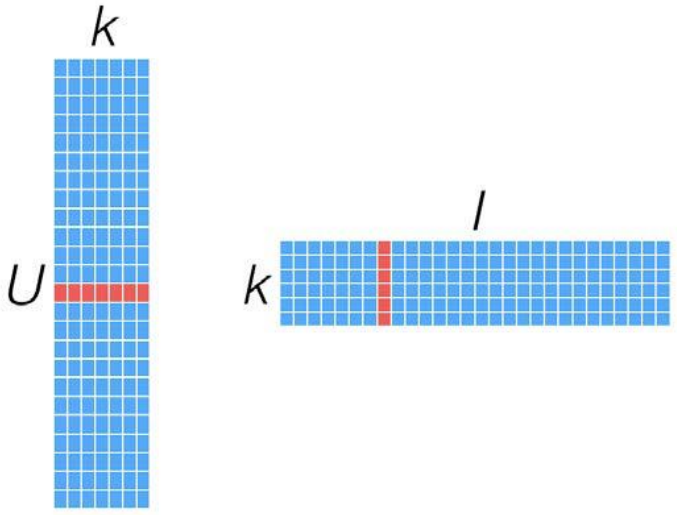

- 透過商品相似性比對找出相似商品

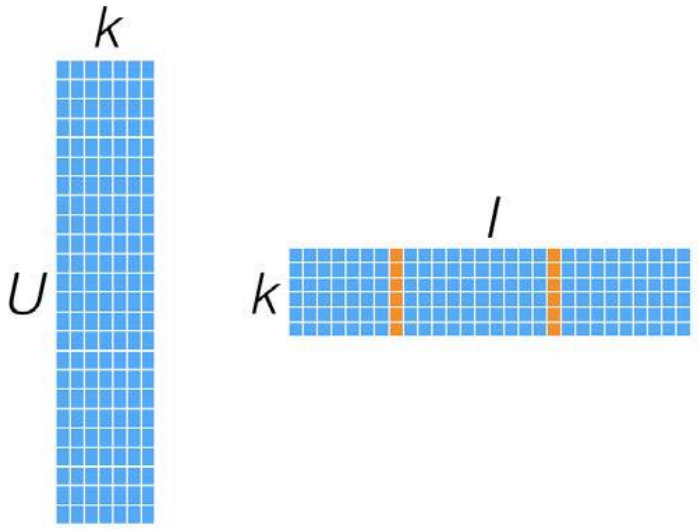

分解矩陣的優缺點

- 優點
  - 容易計算使用者對商品的評分
  - 計算效能高
- 缺點
  - 需要存儲龐大的使用者與商品矩陣
  - 訓練過程的計算量高
  - 比起最近鄰居法難解讀

隱性矩陣分解

- 使用者並未給商品評分，只能從使用者有沒有買過(或看過)該商品，或以看過次數建立分解矩陣

P

User / Item	Batman	Star Wars	Titanic
Bill	1	1	
Jane		1	1
Tom		1	

有看過則填入 1

C

User / Item	Batman	Star Wars	Titanic
Bill	3	3	
Jane		2	4
Tom		5	

依看過次數填入值

得到使用者對商品的偏好，而非評分

ALS 演算法

- **ALS演算法 (Alternating least squares)**
  - 解決矩陣分解的最佳化(Optimization)方法
  - 可運用在平行運算的框架
- 演算法
  - 隨機產生使用者與商品矩陣
  - 固定商品向量以找出最佳使用者向量
    - 根據使用者向量求 RMSE 偏微分為0 的解
  - 固定使用者向量以找出最佳使商品向量
    - 根據商品向量求 RMSE 偏微分為0 的解
  - 迭代迴圈至誤差收斂

Root Mean Squared Error

- Root Mean Squared Error
  - 可以用來評估矩陣重建的誤差
  - 計算預測值與真實值的差距總和
  - 在ALS 演算法中是用來找尋誤差收斂的模型

Root Mean Squared Error

$$RMS = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(y_i - \hat{y}_i\right)^2} = \sqrt{\frac{1}{n}\sum_{i=1}^{n} e_i^2}$$

$$RMS = \sqrt{MSE}$$

預測值與真實值的差距

建立推薦模型

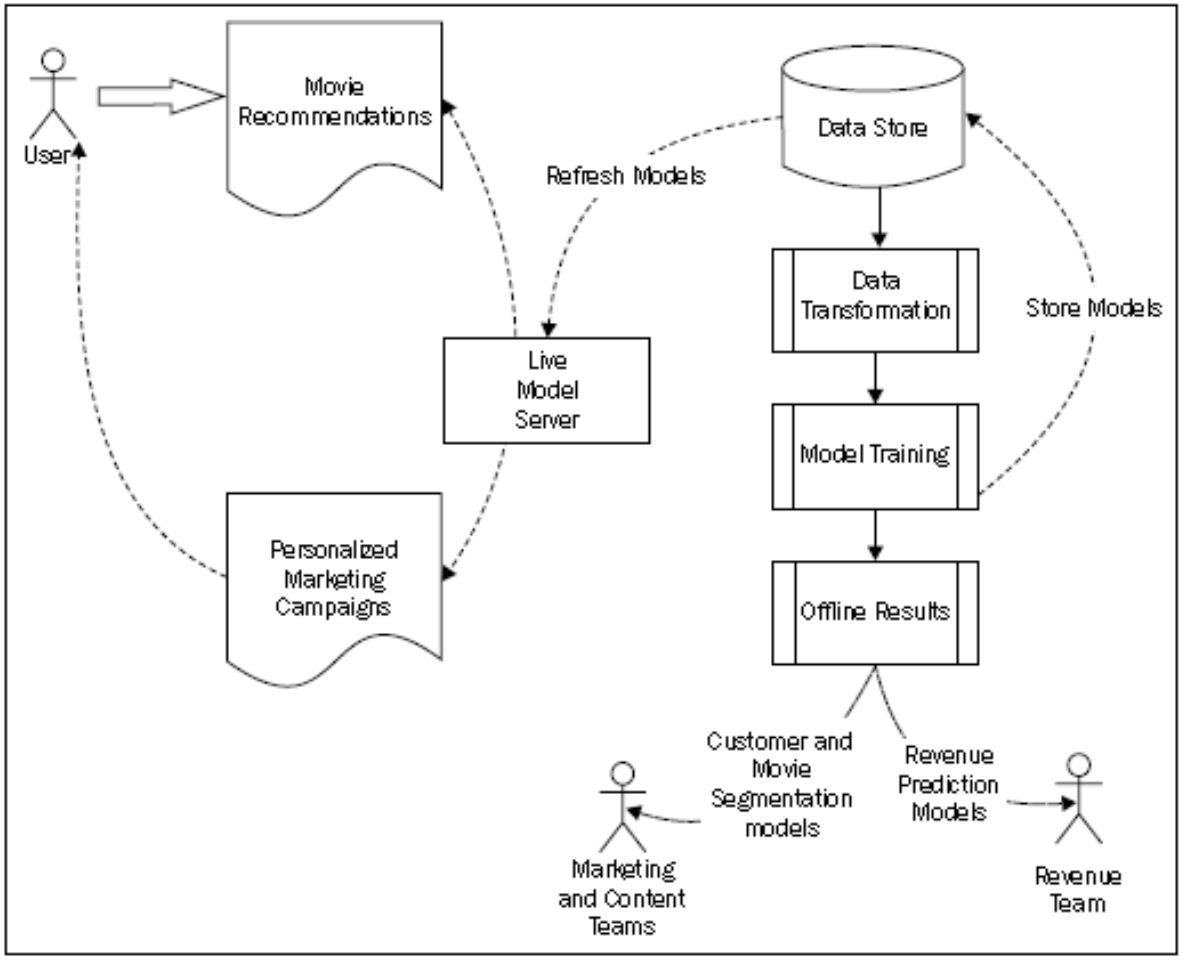

MovieStream's future architecture

下載MovieLens 資料

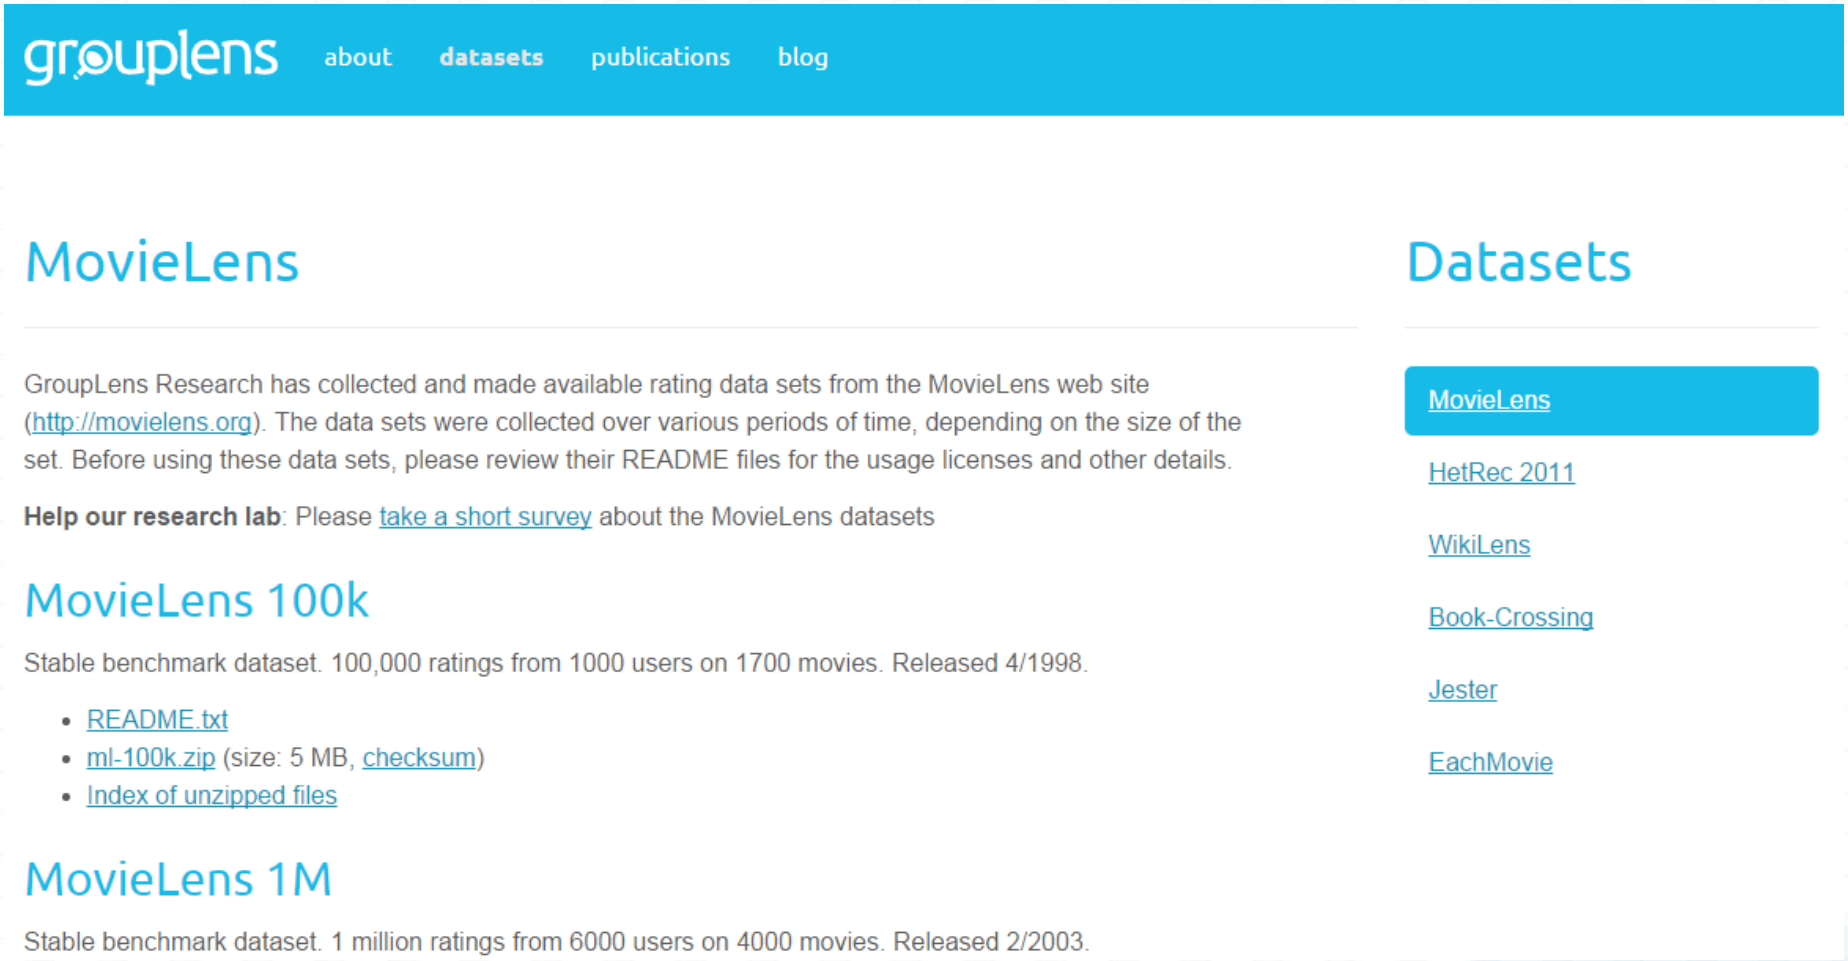

讀取MovieLens 資料

```
%pyspark
rawData = sc.textFile("/tmp/u.data")
rawData.first() #讀取第一列資料

#讀取user id, movie id, ratings
rawRatings = rawData.map(lambda e: e.split())
rawRatings.take(3)
```

將讀取資料讀進Rating 物件

```
from pyspark.sql import Row

#將資料轉進ratingsRDD 物件
ratingsRDD  = rawRatings.map(\
            lambda p: Row(userId=int(p[0]),   \
                        movieId=int(p[1]),  \
                        rating=float(p[2]), \
                        timestamp=int(p[3])))

# 建立 DataFrame
ratings = spark.createDataFrame(ratingsRDD)

# 將資料區分為訓練與測試資料集
(training, test) = ratings.randomSplit([0.8, 0.2])
```

訓練ALS 模型

```
from pyspark.ml.recommendation import ALS

als = ALS(rank=50, maxIter=10, regParam=0.01, \
          userCol="userId", itemCol="movieId", \
          ratingCol="rating")

model = als.fit(training)
```

ALS 模型參數

- Rank
  - 於ALS模型中使用多少隱藏的因素 (k)
  - 數值越大越好，但使用的記憶體越大
  - 設10 ~ 200 是合理的範圍
- Iterations
  - 迴圈數，讓重建矩陣跟實際矩陣的誤差收斂
- regParam
  - 懲罰值，須根據Cross-validation 的結果選擇

何謂regParam (Lambda)

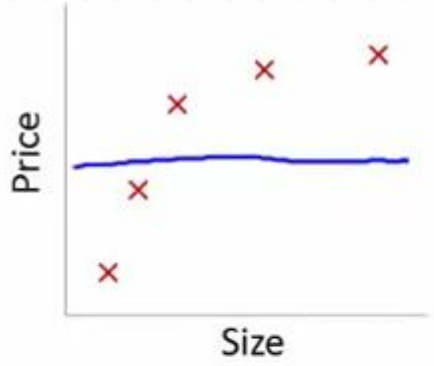

Large λ ←

⇒ High bias (underfit)

$\lambda = 10000.\ \theta_1 \approx 0, \theta_2 \approx 0, \ldots$

$h_\theta(x) \approx \theta_0$

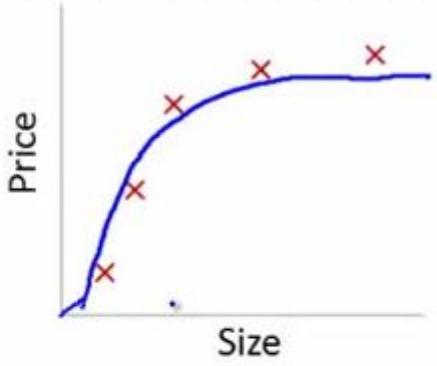

Intermediate λ ←

"Just right"

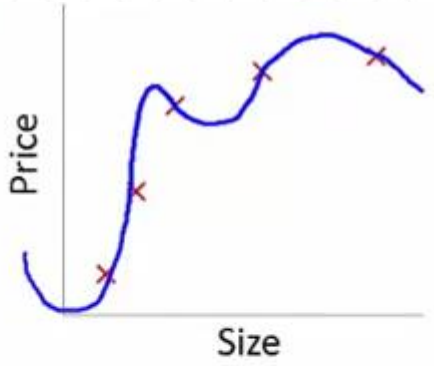

⇒ Small λ

High variance (overfit)

→ $\lambda = 0$

回傳模型

- model
  - 回傳 MatrixFactorizationModel
  - 內含model.userFactors
  - 內含model.itemFactors

- 觸動Spark 動作 (Lazy Transformation)
  - model.userFactors.count()
  - model.itemFactors.count()

隱性回饋資料

- alpha
  - 控制信心權重 (confidence weighting) 的基準值 (baseline)
  - 越高的alpha 代表使用者對缺失值(missing data)的資料是代表使用者對該產品沒有偏好
- 範例

```
model = ALS.trainImplicit(ratings, rank, numIterations, alpha=0.01)
```

求得top-k 的結果

```
# 根據使用者推薦
userRecs = model.recommendForAllUsers(10)

# 根據電影推薦
movieRecs = model.recommendForAllItems(10)
```

透過使用者向量(User Vector)與產品向量(Product Vector)乘積求得使用者對該商品的評分

找出相似性的商品

- Pearson Correlation (real value)
- Cosine Similarity (real value)
- Jaccard Similarity (binary vector)

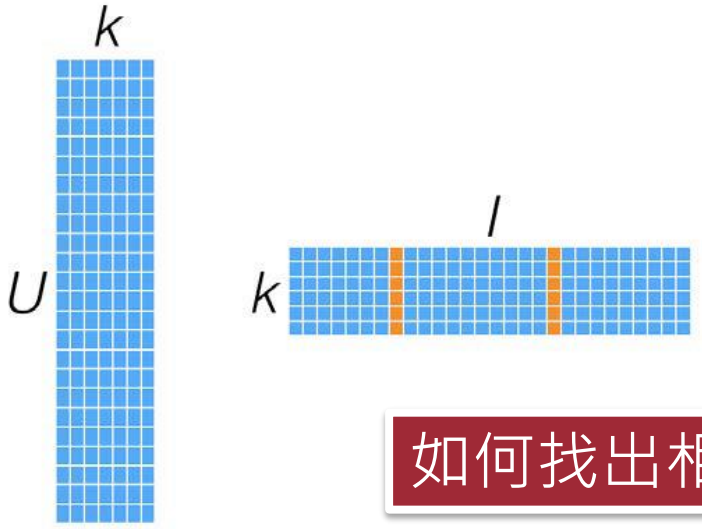

如何找出相似性商品?

計算cosine similarity

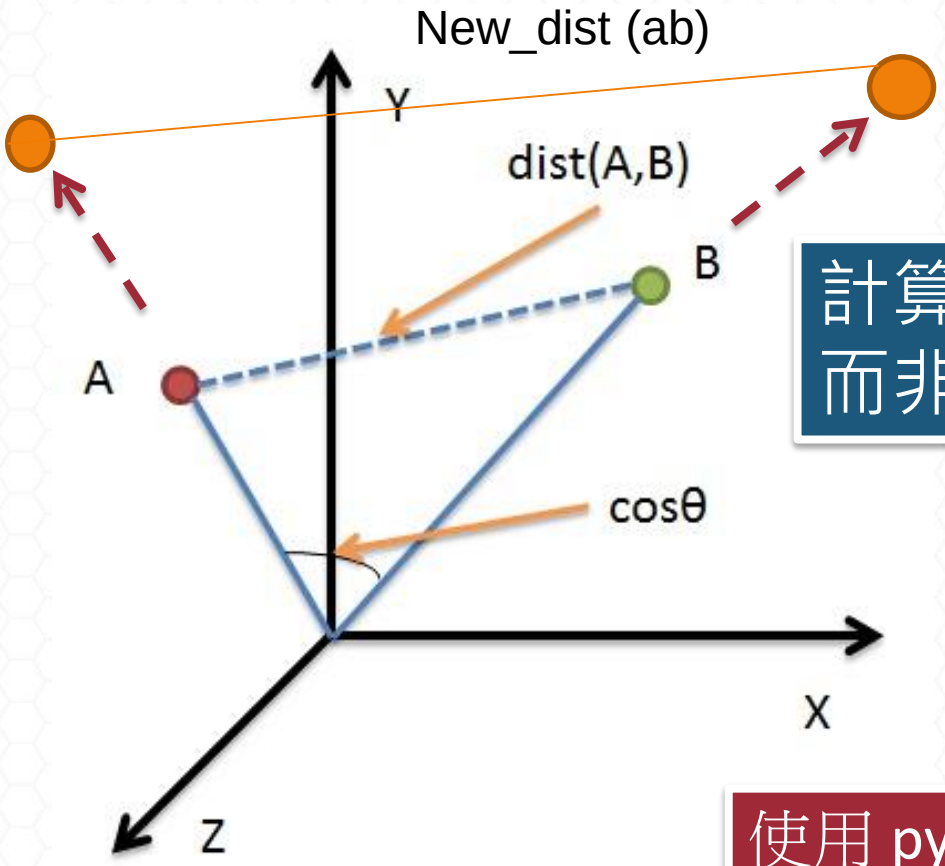

計算相對向量距離
而非絕對距離

使用 pyspark.ml.linalg

建立計算cosine similarity 的公式

```
def cosineSimilarity(x, y):
    return x.dot(y)/(x.norm(2)*y.norm(2))
```

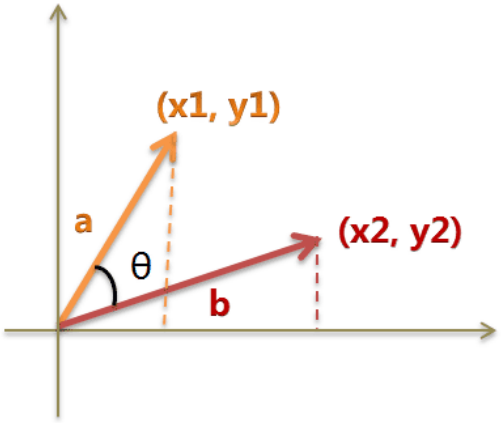

$$\cos\theta = \frac{x_1 x_2 + y_1 y_2}{\sqrt{x_1^2 + y_1^2} \times \sqrt{x_2^2 + y_2^2}}$$

計算物品間的相似度

```
from pyspark.mllib.linalg import Vectors
features = model.itemFactors.filter('id == 567').select('features')
features_vec = features.rdd.map(lambda e: e['features'][0]).collect()
itemVector = Vectors.dense(features_vec)
cosineSimilarity(itemVector, itemVector)
```

自己跟自己的相似度(Cosine Similarity)為1

計算物品與其他物品的相似度

```
from pyspark.mllib.linalg.distributed import RowMatrix,
IndexedRowMatrix,IndexedRow
from pyspark.mllib.linalg.distributed import CoordinateMatrix,
MatrixEntry

mat = IndexedRowMatrix(model.itemFactors.rdd.map(lambda x:
IndexedRow(x[0],x[1]))).toBlockMatrix().transpose().toIndexedRowMatri
x()

exact = mat.columnSimilarities()
res = exact.entries.collect()
for ele in res:
    print(ele.i, ele.j, ele.value)
```

評估推薦模型的好壞

- Mean Squared Error
  - 計算預測值與實際值的誤差

Root Mean Squared Error

$$RMS = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(y_i - \hat{y}_i\right)^2} = \sqrt{\frac{1}{n}\sum_{i=1}^{n} e_i^2}$$

$$RMS = \sqrt{MSE}$$

- Mean average precision at K
  - 計算top-k 物件的相關性

計算Root Mean Square Error

- Root Mean Square Error
  - 與真實資料同個單位
  - MSE 開根號

使用內建的RegressionMetrics計算

```
from pyspark.ml.evaluation import RegressionEvaluator

predictions = model.transform(test)
evaluator = RegressionEvaluator(metricName="rmse",
labelCol="rating",
                                predictionCol="prediction")
rmse = evaluator.evaluate(predictions)
print("Root-mean-square error = " + str(rmse))
```

THANK YOU